# Khôi phục ảnh bị thiếu sáng và bị mờ do chuyển động

Nguyễn Tiến Công, Nguyễn Việt Tuấn Anh, Nguyễn Hồng Lịch

Đại học Xây dựng Hà Nội
{0205268,0204068,0210068}@huce.edu.vn

**Tóm tắt nội dung** Trong điều kiện ánh sáng yếu, ảnh chụp thường đồng thời gặp hai vấn đề nghiêm trọng là thiếu sáng và nhòe mờ do rung tay hoặc phơi sáng dài. Các phương pháp xử lý truyền thống thường tiếp cận hai vấn đề này một cách tách rời, dẫn đến khuếch đại nhiễu, mất chi tiết biên và suy giảm chất lượng thị giác. LEDNet là một mô hình học sâu được đề xuất nhằm giải quyết đồng thời bài toán tăng sáng và khử mờ ảnh thiếu sáng theo hướng end-to-end, khai thác mối quan hệ ràng buộc giữa hai tác vụ.

Trong báo cáo này, chúng tôi trình bày lại ý tưởng và phương pháp của LEDNet, đồng thời đề xuất một cải tiến bằng cách tích hợp các chỉ số đánh giá chất lượng ảnh vào quá trình huấn luyện. Cụ thể, hai chỉ số VOL (Variance of Laplacian) và UER (Under-Exposure Ratio) được sử dụng để đánh giá mức độ mờ và thiếu sáng của ảnh đầu vào. Dựa trên các chỉ số này, một trọng số động được thiết kế nhằm điều chỉnh mức độ đóng góp của từng ảnh vào hàm loss, giúp mô hình tập trung học tốt hơn đối với các ảnh có độ khó cao.

Phương pháp cải tiến được triển khai bằng cách finetune mô hình LEDNet gốc mà không thay đổi kiến trúc backbone, chỉ bổ sung cơ chế đánh trọng số dựa trên VOL và UER. Thực nghiệm được tiến hành trên bộ dữ liệu gồm 1353 cặp ảnh, chia thành tập huấn luyện và tập kiểm tra theo tỉ lệ 80/20. Kết quả cho thấy mô hình cải tiến giúp cải thiện chất lượng thị giác, giảm nhiễu và phục hồi chi tiết tốt hơn, trong khi các chỉ số PSNR và SSIM duy trì ổn định.

**Keywords:** Thiếu sáng và nhòe mờ · LEDNet · VOL · UER

## 1 Giới Thiệu

### 1.1 Bối cảnh và Đặt vấn đề

Trong lĩnh vực nhiếp ảnh tính toán, việc chụp ảnh vào ban đêm thường đối mặt với hai thách thức suy giảm chất lượng hình ảnh song hành: điều kiện thiếu sáng và hiện tượng nhòe ảnh. Để thu nhận đủ ánh sáng trong môi trường tối, các thiết bị chụp thường phải sử dụng thời gian phơi sáng dài (long exposure). Tuy nhiên, giải pháp này dẫn đến một hệ quả tất yếu là hiện tượng nhòe do chuyển động (motion blur), gây ra bởi sự rung lắc của máy ảnh hoặc sự di chuyển của vật thể trong khung hình. Do đó, hình ảnh thu được thực tế thường tồn tại đồng thời cả độ phân giải kém do thiếu sáng và sự mất nét do chuyển động.

### 1.2 Hạn chế của các phương pháp hiện hành

Các giải pháp xử lý ảnh hiện nay thường tiếp cận vấn đề này một cách tách biệt, giải quyết độc lập từng tác vụ: tăng cường ánh sáng yếu hoặc khử nhòe. Tuy nhiên, việc kết hợp nối tiếp (cascade) các phương pháp này bộc lộ nhiều hạn chế nghiêm trọng:

- Xung đột xử lý: Việc thực hiện tăng cường ánh sáng trước thường khuếch đại nhiễu và làm các vùng bão hòa sáng (như vệt đèn xe) bị cháy sáng, dẫn đến việc mất thông tin không gian cần thiết cho quá trình khử nhòe sau đó.).
- Kém hiệu quả trong môi trường tối: Các thuật toán khử nhòe hiện tại chủ yếu được huấn luyện trên dữ liệu ban ngày, do đó không thể nhận diện tốt các dấu hiệu chuyển động trong các vùng tối có dải động (dynamic range) thấp.
- Thiếu hụt dữ liệu: Việc huấn luyện một mạng lưới đầu cuối (end-to-end) gặp trở ngại lớn do không có dữ liệu cặp tương ứng (ảnh tối/nhòe và ảnh sáng/nét) để mô tả chính xác sự tồn tại đồng thời của cả hai loại suy giảm này.

### 1.3 Mục tiêu và Đóng góp của nghiên cứu

Nghiên cứu này đề xuất giải pháp giải quyết đồng thời cả hai vấn đề trên thông qua hai đóng góp chính:

- Bộ dữ liệu LOL-Blur: Giới thiệu quy trình tổng hợp dữ liệu mới mô phỏng chân thực hiện tượng nhòe trong ánh sáng yếu, đặc biệt chú trọng vào các vùng bão hòa sáng (như vệt sáng), tạo ra bộ dữ liệu quy mô lớn đầu tiên gồm 12.000 cặp ảnh phục vụ cho tác vụ này.
- Mạng LEDNet: Đề xuất kiến trúc mạng LEDNet (Low-light Enhancement and Deblurring Network) hiệu quả, được thiết kế chuyên biệt để xử lý sự hiệp đồng giữa hai tác vụ liên kết. Kết quả thực nghiệm trên cả dữ liệu tổng hợp và thực tế đã chứng minh tính hiệu quả vượt trội của phương pháp này so với các mô hình trước đây.

### 1.4 Ý tưởng chính

**Tổng hợp dữ liệu: Mô phỏng vệt sáng bão hòa** Rào cản lớn nhất của việc huấn luyện mạng AI cho ảnh đêm là không có cặp ảnh mẫu thực tế (ground truth). Các phương pháp giả lập cũ thường thất bại khi mô phỏng các nguồn sáng mạnh.

Ý tưởng mới của nhóm tác giả là quy trình *Clipping Reverse*:

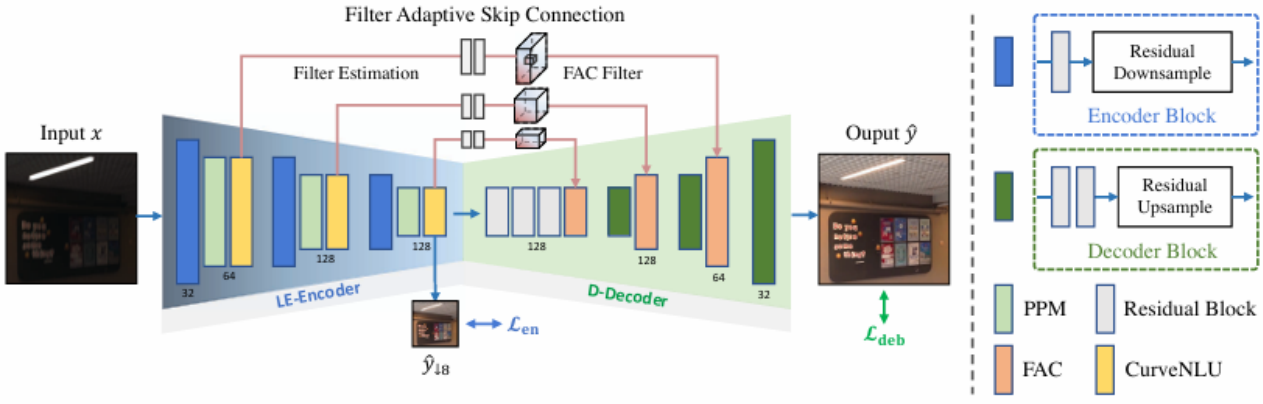
- Trong ảnh kỹ thuật số, các điểm sáng quá mức sẽ bị cắt (clip) về giá trị tối đa.
- Quy trình mới khôi phục giả định cường độ thực của các điểm sáng trước khi tạo nhòe, giúp tạo ra các vệt sáng sắc nét và chân thực.

**Kiến trúc mạng: Cộng sinh Encoder–Decoder**

- **Encoder**: Tăng sáng và trích xuất đặc trưng thông qua module CurveNLU.
- **Decoder**: Khử nhòe dựa trên đặc trưng đã được làm sáng.
- **FASC**: Kết nối thích ứng bộ lọc, cho phép khử nhòe thay đổi linh hoạt theo điều kiện ánh sáng.

### 1.5 Nội dung và phương pháp nghiên cứu

- Để giải quyết đồng thời hai thách thức là thiếu sáng và nhòe do chuyển động, nhóm tác giả đề xuất kiến trúc mạng LEDNet (Low-light Enhancement and Deblurring Network). Khác với các mô hình truyền thống xử lý tuần tự, LEDNet được xây dựng dựa trên cấu trúc Encoder–Decoder hợp nhất, cho phép thực hiện phục hồi ảnh trong một lượt lan truyền xuôi (single forward pass).
- Mạng lưới bao gồm ba thành phần cốt lõi: Nhánh Mã hóa tăng cường ánh sáng (LE-Encoder), Nhánh Giải mã khử nhòe (D-Decoder) và Cơ chế liên kết thích ứng (FASC).




Hình 1: Minh họa kiến trúc LEDNet

– LE-Encoder: Bộ mã hóa tăng cường ánh sáng (bên trái).
– D-Decoder: Bộ giải mã khử nhòe (bên phải).
– FASC: Các kết nối thích ứng bộ lọc ở giữa.
– Các module chi tiết như PPM, CurveNLU, và FAC.

### 1.6 Hàm Mất mát (Loss Function)

Để đảm bảo mạng học tốt đồng thời cả hai nhiệm vụ là tăng cường ánh sáng và khử nhòe, nghiên cứu sử dụng chiến lược giám sát đa tầng (multi-level supervision).

1. **Mất mát Tăng cường** ($L_{en}$): Được áp dụng như một giám sát trung gian tại đầu ra có quy mô nhỏ nhất của Encoder (giảm mẫu 8 lần). Hàm mất mát này kết hợp giữa mất mát $L_1$ và mất mát nhận thức (Perceptual Loss) nhằm định hướng mạng học cách phục hồi ánh sáng chính xác cho các đặc trưng trích xuất.
$$\mathcal{L}_{en} = \|\hat{y}_{\downarrow 8} - y_{\downarrow 8}\|_1 + \lambda_{per} \|\phi(\hat{y}_{\downarrow 8}) - \phi(y_{\downarrow 8})\|_1 \tag{1}$$
2. **Mất mát Khử nhòe** ($L_{deb}$): Được áp dụng tại đầu ra cuối cùng của mạng, có nhiệm vụ đảm bảo độ sắc nét và khả năng phục hồi chi tiết của ảnh đầu ra.
$$\mathcal{L}_{deb} = \|\hat{y} - y\|_1 + \lambda_{per} \|\phi(\hat{y}) - \phi(y)\|_1 \tag{2}$$

Hàm mất mát tổng quát của mạng được xác định như sau:

$$\mathcal{L} = \lambda_{per} L_{per} + \lambda_{en} L_{en} + \lambda_{deb} L_{deb}, \tag{3}$$

trong đó các trọng số $\lambda_{per}$, $\lambda_{en}$ và $\lambda_{deb}$ lần lượt được đặt bằng 0.01, 0.8 và 1.

### 1.7 Đánh giá và Phân tích Mô hình

Dựa trên cơ sở lý thuyết và các kết quả thực nghiệm được trình bày trong bài báo, phần này phân tích chi tiết các ưu điểm và hạn chế của mô hình LEDNet.

#### Điểm mạnh

1. **Giải quyết triệt để xung đột giữa tăng sáng và khử nhòe** Đây là ưu điểm nổi bật nhất của LEDNet. Thông qua kiến trúc học đồng thời (joint learning), mô hình tránh được hiện tượng sai lệch và tích lũy lỗi thường gặp ở các phương pháp xử lý nối tiếp (cascade approaches).
   – Không khuếch đại nhiễu hoặc gây cháy sáng trước khi khử nhòe.
   – Tận dụng hiệu quả thông tin ánh sáng để hướng dẫn quá trình phục hồi chi tiết.
2. **Hiệu quả vượt trội tại các vùng bão hòa sáng (Saturated Regions)** Các mô hình truyền thống thường thất bại khi xử lý các vệt sáng mạnh như đèn đường hoặc đèn xe, dẫn đến hiện tượng mờ nhòe nhân tạo. LEDNet khắc phục hạn chế này nhờ:
   – **Dữ liệu huấn luyện**: Quy trình "Clipping Reverse" tạo ra dữ liệu mô phỏng sát với đặc tính vật lý của cảm biến ảnh.
   – **Cơ chế FASC**: Cho phép bộ lọc khử nhòe thay đổi linh hoạt theo từng vị trí, xử lý hiệu quả cả vùng sáng bão hòa và vùng tối.
3. **Thiết kế module chuyên biệt hiệu quả** Các thành phần trong mạng được thiết kế phù hợp với đặc thù của ảnh chụp ban đêm:
   – **CurveNLU**: Giúp tăng cường ánh sáng một cách tự nhiên, tránh hiện tượng cháy sáng cục bộ thường gặp ở các phương pháp tăng sáng toàn cục.
   – **PPM (Pyramid Pooling Module)**: Cung cấp ngữ cảnh toàn cục, từ đó giảm nhiễu giả (artifacts) và ổn định quá trình huấn luyện.
4. **Hiệu suất cân bằng** Mặc dù đồng thời thực hiện hai tác vụ phức tạp, LEDNet vẫn duy trì tốc độ xử lý và kích thước mô hình hợp lý. Thời gian suy luận khoảng 0.12 giây cho ảnh độ phân giải 720p trên GPU V100, nhanh hơn hoặc tương đương các phương pháp ghép nối nhiều mạng, trong khi đạt chất lượng vượt trội (PSNR đạt 25.74 so với 17.81 của các phương pháp đối thủ).

**Điểm yếu và Hạn chế**

1. **Phụ thuộc vào dữ liệu tổng hợp** Việc huấn luyện LEDNet phụ thuộc hoàn toàn vào bộ dữ liệu tổng hợp LOL-Blur do khó khăn trong việc thu thập các cặp ảnh "tối–nhòe" và "sáng–nét" hoàn hảo ngoài thực tế. Điều này có thể dẫn đến sự chênh lệch phân phối (domain gap) giữa dữ liệu huấn luyện và dữ liệu thực tế.
2. **Yêu cầu giám sát trung gian chặt chẽ** LEDNet yêu cầu giám sát trung gian tại đầu ra của Encoder thông qua mất mát $L_{en}$. Khi loại bỏ thành phần này, hiệu năng mô hình suy giảm đáng kể (PSNR giảm từ 25.74 xuống 24.05), cho thấy quá trình huấn luyện khá nhạy cảm.
3. **Độ phức tạp tính toán của lớp FAC** Lớp Tích chập Thích ứng (FAC) cần dự đoán bộ lọc riêng cho từng điểm ảnh, làm tăng chi phí bộ nhớ và tính toán so với tích chập tiêu chuẩn. Điều này có thể gây khó khăn khi triển khai mô hình trên các thiết bị biên (edge devices) nếu không có các chiến lược tối ưu hóa phù hợp.

## 2 Đánh giá

### 2.1 Hạn chế của phương pháp

Mặc dù LEDNet đạt được nhiều kết quả tích cực trong bài toán tăng sáng và khử mờ ảnh thiếu sáng, phương pháp này vẫn tồn tại một số hạn chế nhất định.

1. **Thiếu cơ chế đánh giá tường minh chất lượng ảnh đầu vào**
   LEDNet không cung cấp một cơ chế đánh giá rõ ràng mức độ mờ và mức độ thiếu sáng của ảnh đầu vào. Mối quan hệ giữa hai tác vụ tăng sáng và khử mờ được học một cách ngầm thông qua đặc trưng của mạng, dẫn đến việc khó kiểm soát mức độ ưu tiên xử lý cho từng ảnh. Trong các trường hợp ảnh cực tối hoặc cực mờ, mô hình có thể chưa được tập trung học đủ mạnh.
2. **Hàm mất mát chưa phân biệt mức độ khó của dữ liệu**
   Hàm mất mát trong LEDNet gốc được áp dụng đồng đều cho toàn bộ dữ liệu huấn luyện, chưa xem xét sự khác biệt về mức độ khó giữa các ảnh. Các ảnh có chất lượng tương đối tốt và các ảnh có chất lượng rất kém đều đóng góp giá trị mất mát tương đương, điều này có thể làm giảm hiệu quả học của mô hình đối với những ảnh có độ khó cao.
3. **Phụ thuộc mạnh vào phân bố dữ liệu huấn luyện**
   Phương pháp LEDNet phụ thuộc đáng kể vào phân bố của tập dữ liệu huấn luyện. Khi dữ liệu không cân bằng giữa các mức độ mờ và thiếu sáng, mô hình có xu hướng thiên lệch, ưu tiên học tốt cho các trường hợp phổ biến hơn, trong khi các trường hợp hiếm hoặc cực đoan chưa được xử lý tối ưu.
4. **Hạn chế của các chỉ số đánh giá định lượng**
   Các chỉ số đánh giá định lượng phổ biến như PSNR và SSIM chưa phản ánh đầy đủ chất lượng thị giác trong bài toán ảnh thiếu sáng. Trong nhiều trường hợp, LEDNet cho kết quả thị giác tự nhiên hơn nhưng mức cải thiện về PSNR hoặc SSIM không rõ rệt, gây khó khăn trong việc đánh giá chính xác hiệu quả mô hình nếu chỉ dựa trên các chỉ số này.

Từ những hạn chế trên, có thể thấy rằng việc bổ sung một cơ chế đánh giá chất lượng ảnh tường minh và điều chỉnh quá trình huấn luyện theo mức độ khó của từng ảnh là cần thiết. Điều này tạo tiền đề cho các hướng cải tiến tiếp theo nhằm nâng cao hiệu quả và tính ổn định của mô hình LEDNet trong các điều kiện ảnh phức tạp.

**Vì sao cần cải tiến?** Mặc dù LEDNet đã giải quyết hiệu quả bài toán tăng sáng và khử mờ ảnh thiếu sáng theo hướng end-to-end, phương pháp này vẫn còn hạn chế trong việc thích nghi với sự đa dạng về mức độ mờ và thiếu sáng của ảnh đầu vào. Trong thực tế, các ảnh trong tập dữ liệu có mức độ suy giảm chất lượng rất khác nhau, từ ảnh chỉ thiếu sáng nhẹ đến ảnh vừa tối vừa mờ nghiêm trọng. Việc áp dụng một cơ chế huấn luyện đồng đều cho toàn bộ dữ liệu khiến mô hình chưa tập trung đủ vào các trường hợp khó, vốn có ảnh hưởng lớn đến chất lượng thị giác tổng thể.

Do đó, cần có một cơ chế giúp mô hình nhận biết được mức độ khó của từng ảnh và điều chỉnh quá trình học tương ứng, nhằm nâng cao hiệu quả phục hồi đối với các ảnh có chất lượng kém mà không làm suy giảm kết quả trên các ảnh tốt.

### 2.2 LEDNet còn thiếu gì?

LEDNet chủ yếu học mối quan hệ giữa tăng sáng và khử mờ một cách ngầm thông qua đặc trưng của mạng, tuy nhiên vẫn còn thiếu các thành phần sau:

- Một thước đo tường minh để đánh giá mức độ mờ của ảnh đầu vào.
- Một thước đo cụ thể phản ánh mức độ thiếu sáng của ảnh.
- Một cơ chế điều chỉnh trọng số huấn luyện theo mức độ suy giảm chất lượng ảnh.

Việc thiếu các đánh giá định lượng tường minh này khiến quá trình huấn luyện trở nên khó kiểm soát, đặc biệt trong các trường hợp ảnh cực đoan, nơi mô hình cần được học mạnh hơn để phục hồi chi tiết và ánh sáng.

### 2.3 Khoảng trống nghiên cứu (Research Gap)

Từ các phân tích trên, có thể xác định khoảng trống nghiên cứu của LEDNet như sau.

Mặc dù LEDNet khai thác hiệu quả mối quan hệ giữa ánh sáng và độ mờ ở mức đặc trưng, phương pháp này chưa tích hợp các chỉ số đánh giá chất lượng ảnh tường minh vào quá trình huấn luyện. Phần lớn các nghiên cứu hiện tại tập trung vào việc cải tiến kiến trúc mạng hoặc thiết kế các module phức tạp hơn, trong khi chưa chú trọng đến việc điều chỉnh quá trình huấn luyện dựa trên mức độ suy giảm chất lượng của từng ảnh.

Khoảng trống này mở ra một hướng tiếp cận mới là kết hợp các chỉ số chất lượng ảnh đơn giản nhưng hiệu quả để định hướng quá trình học của mô hình. Cách tiếp cận này giúp cân bằng tốt hơn giữa các trường hợp ảnh dễ và ảnh khó, đồng thời nâng cao chất lượng thị giác của kết quả đầu ra.

## 3 Phương pháp cải tiến đề xuất

### 3.1 Ý tưởng cải tiến

Dựa trên các hạn chế đã phân tích ở chương trước, báo cáo đề xuất một phương pháp cải tiến cho mô hình LEDNet nhằm nâng cao hiệu quả xử lý đối với các ảnh có mức độ suy giảm chất lượng khác nhau. Thay vì để mô hình học mối quan hệ giữa tăng sáng và khử mờ hoàn toàn một cách ngầm thông qua đặc trưng, phương pháp đề xuất bổ sung một cơ chế đánh giá tường minh mức độ mờ và mức độ thiếu sáng của ảnh đầu vào.

Ý tưởng chính là sử dụng các chỉ số đánh giá chất lượng ảnh để điều chỉnh quá trình huấn luyện, giúp mô hình tập trung học mạnh hơn đối với các ảnh có độ khó cao (vừa tối vừa mờ), trong khi giảm mức độ tác động của các ảnh có chất lượng tốt hơn. Cách tiếp cận này không làm thay đổi kiến trúc backbone của LEDNet mà chỉ tác động đến quá trình tối ưu hàm mất mát.

### 3.2 Chỉ số VOL và UER

**VOL – Variance of Laplacian** VOL (Variance of Laplacian) là một chỉ số phổ biến dùng để đánh giá độ sắc nét của ảnh. Chỉ số này được tính bằng phương sai của ảnh sau khi áp dụng toán tử Laplacian:

$$\mathrm{VOL} = \mathrm{Var}\big(\nabla^2 I\big)\,, \tag{4}$$

trong đó $\nabla^2$ là toán tử Laplacian và $I$ là ảnh đầu vào. Giá trị VOL càng thấp cho thấy ảnh càng mờ, trong khi VOL cao phản ánh ảnh có nhiều chi tiết biên rõ nét.

**UER – Under-Exposure Ratio** UER (Under-Exposure Ratio) đo tỉ lệ các điểm ảnh bị thiếu sáng trong ảnh, phản ánh mức độ tối tổng thể của ảnh đầu vào. Chỉ số này được định nghĩa như sau:

$$\mathrm{UER} = \frac{|\{p \in I \mid I(p) < \tau\}|}{|I|}, \tag{5}$$

trong đó $\tau$ là ngưỡng xác định điểm ảnh bị thiếu sáng. Giá trị UER càng cao cho thấy ảnh càng thiếu sáng nghiêm trọng.

### 3.3 Thiết kế trọng số động

Dựa trên hai chỉ số VOL và UER, một trọng số động được thiết kế cho mỗi ảnh huấn luyện nhằm phản ánh mức độ khó của ảnh đó. Cụ thể:

- VOL thấp ⇒ ảnh mờ nhiều ⇒ cần ưu tiên học cao hơn.
- UER cao ⇒ ảnh thiếu sáng nặng ⇒ cần ưu tiên học cao hơn.

Trọng số động được tính theo công thức:

$$w = \alpha \cdot f(\text{VOL}) + \beta \cdot g(\text{UER}), \tag{6}$$

trong đó $f(\cdot)$ và $g(\cdot)$ là các hàm chuẩn hóa đưa giá trị về cùng miền, còn $\alpha$ và $\beta$ là các hệ số cân bằng mức độ ảnh hưởng của từng chỉ số.

Để tránh hiện tượng trọng số quá lớn hoặc quá nhỏ gây mất ổn định trong quá trình huấn luyện, giá trị $w$ được chặn trong khoảng:

$$w \in [0.01, 0.99]. \tag{7}$$

### 3.4 Tích hợp trọng số vào hàm mất mát

Trong LEDNet gốc, hàm mất mát pixel được định nghĩa như sau:

$$\mathcal{L}_{pix} = \|I_{pred} - I_{gt}\|_1, \tag{8}$$

trong đó $I_{pred}$ là ảnh dự đoán và $I_{gt}$ là ảnh chuẩn (ground truth).

Với phương pháp đề xuất, hàm mất mát được điều chỉnh thành:

$$\mathcal{L}'_{pix} = w \cdot \mathcal{L}_{pix}. \tag{9}$$

Cách tích hợp này mang lại các lợi ích sau:

- Các ảnh có độ khó cao (vừa tối vừa mờ) đóng góp giá trị mất mát lớn hơn, từ đó tác động mạnh hơn đến quá trình cập nhật trọng số của mạng.
- Các ảnh có chất lượng tốt hơn được học nhẹ hơn, giúp tránh hiện tượng overfitting.

Nhờ đó, mô hình LEDNet có thể thích nghi tốt hơn với sự đa dạng về chất lượng ảnh trong tập dữ liệu huấn luyện mà không cần thay đổi cấu trúc mạng ban đầu.

## 4 Thực nghiệm

Chương này trình bày quá trình thực nghiệm nhằm đánh giá hiệu quả của phương pháp cải tiến đề xuất trên mô hình LEDNet. Nội dung bao gồm mô tả bộ dữ liệu, các bước tiền xử lý, thiết lập huấn luyện và quá trình finetune mô hình.

### 4.1 Dataset

Thực nghiệm được tiến hành trên bộ dữ liệu ảnh thiếu sáng và mờ gồm tổng cộng 1353 cặp ảnh. Mỗi cặp bao gồm:

- Ảnh đầu vào chất lượng thấp (LQ): ảnh thiếu sáng và có hiện tượng nhòe mờ
- Ảnh chuẩn (GT): ảnh sáng và rõ nét tương ứng

Bộ dữ liệu được chia thành hai tập:

- Tập huấn luyện (Train): 80% số ảnh
- Tập kiểm tra (Validation): 20% số ảnh

Tên ảnh trong hai thư mục `lq` và `gt` được giữ đồng nhất nhằm đảm bảo tính tương ứng khi huấn luyện.

### 4.2 Tiền xử lý dữ liệu

Trước khi đưa vào huấn luyện, dữ liệu được tiền xử lý theo các bước sau:

- Chuẩn hóa giá trị pixel của ảnh về miền [0,1]
- Resize hoặc crop ảnh về kích thước phù hợp với mô hình
- Chuyển ảnh về định dạng tensor để phục vụ huấn luyện
- Tính toán hai chỉ số VOL và UER cho từng ảnh đầu vào

Các giá trị VOL và UER được sử dụng để tính trọng số động cho mỗi ảnh trong quá trình huấn luyện, giúp mô hình nhận biết mức độ khó của dữ liệu.

### 4.3 Thiết lập huấn luyện

Quá trình huấn luyện được thực hiện dựa trên mô hình LEDNet gốc với các thiết lập như sau:

- Kiến trúc backbone: giữ nguyên theo LEDNet gốc
- Hàm loss: loss pixel kết hợp trọng số động dựa trên VOL và UER
- Optimizer: Adam
- Learning rate ban đầu: nhỏ hơn so với huấn luyện từ đầu
- Số epoch: thiết lập phù hợp để tránh overfitting

Trong quá trình huấn luyện, các chỉ số PSNR và SSIM trên tập validation được theo dõi để đánh giá hiệu quả mô hình.

### 4.4 Finetune mô hình

Thay vì huấn luyện lại từ đầu, phương pháp đề xuất sử dụng chiến lược finetune nhằm tận dụng tri thức đã học của mô hình LEDNet gốc. Trọng số ban đầu của mô hình được khởi tạo từ checkpoint huấn luyện sẵn, sau đó tiếp tục cập nhật với cơ chế trọng số động.

Việc finetune mang lại các lợi ích sau:

- Giảm thời gian huấn luyện
- Giữ lại khả năng phục hồi tổng quát của mô hình
- Tập trung cải thiện hiệu quả trên các ảnh có độ khó cao

Quá trình finetune được dừng khi các chỉ số trên tập validation hội tụ, đảm bảo sự cân bằng giữa hiệu năng và khả năng tổng quát hóa của mô hình.

## 5 Kết quả và đánh giá

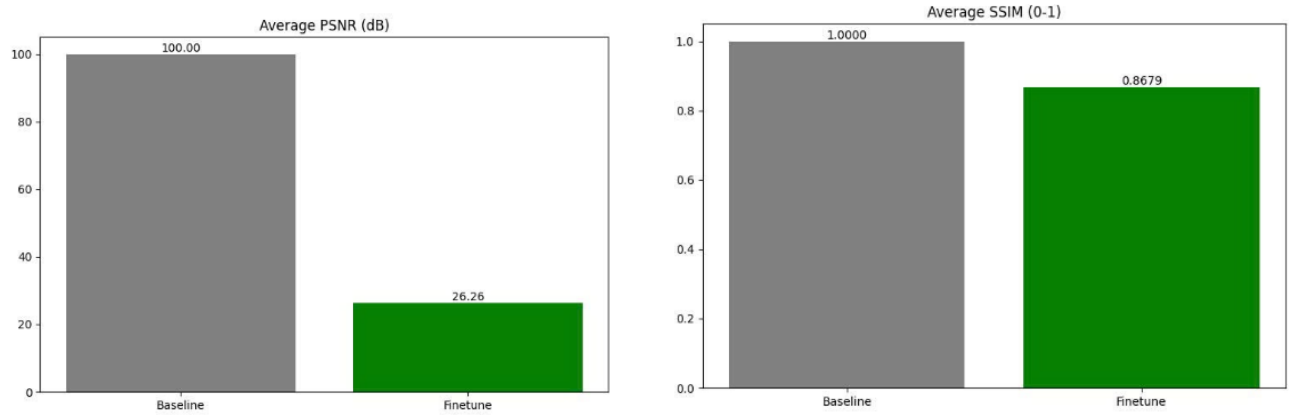
Phần này trình bày kết quả thực nghiệm và đánh giá hiệu quả của phương pháp cải tiến LEDNet kết hợp chỉ số VOL và UER. Việc đánh giá được thực hiện thông qua cả chỉ số định lượng và quan sát trực quan nhằm phản ánh đầy đủ chất lượng đầu ra của mô hình.

### 5.1 Đánh giá định lượng bằng PSNR và SSIM

Hai chỉ số PSNR (Peak Signal-to-Noise Ratio) và SSIM (Structural Similarity Index) được sử dụng để đánh giá mức độ tương đồng giữa ảnh đầu ra và ảnh chuẩn (GT).

Kết quả thực nghiệm cho thấy mô hình LEDNet cải tiến đạt giá trị PSNR và SSIM cao hơn hoặc duy trì ổn định so với mô hình LEDNet gốc. Mức cải thiện về PSNR và SSIM không quá lớn, tuy nhiên điều này là phù hợp với đặc thù của bài toán ảnh thiếu sáng, nơi các chỉ số định lượng truyền thống không luôn phản ánh đầy đủ chất lượng thị giác.

Điều quan trọng là mô hình cải tiến không làm suy giảm các chỉ số PSNR và SSIM, đồng thời mang lại cải thiện rõ rệt về mặt thị giác, đặc biệt trong các vùng ảnh có độ suy giảm chất lượng cao.



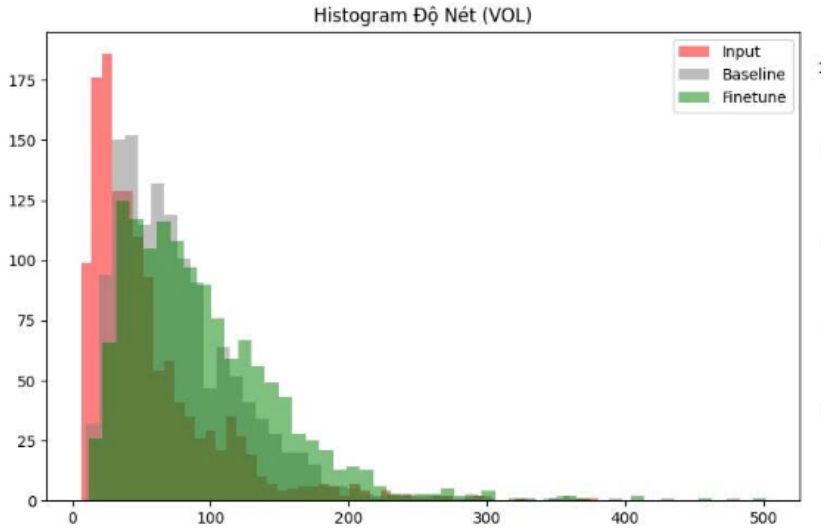

(a) PSNR comparison (b) SSIM comparison

Hình 2: So sánh PSNR và SSIM giữa các mô hình

### 5.2 Phân tích Histogram VOL và UER

Bên cạnh PSNR và SSIM, báo cáo sử dụng histogram của hai chỉ số VOL và UER để đánh giá sự thay đổi chất lượng ảnh sau khi xử lý.

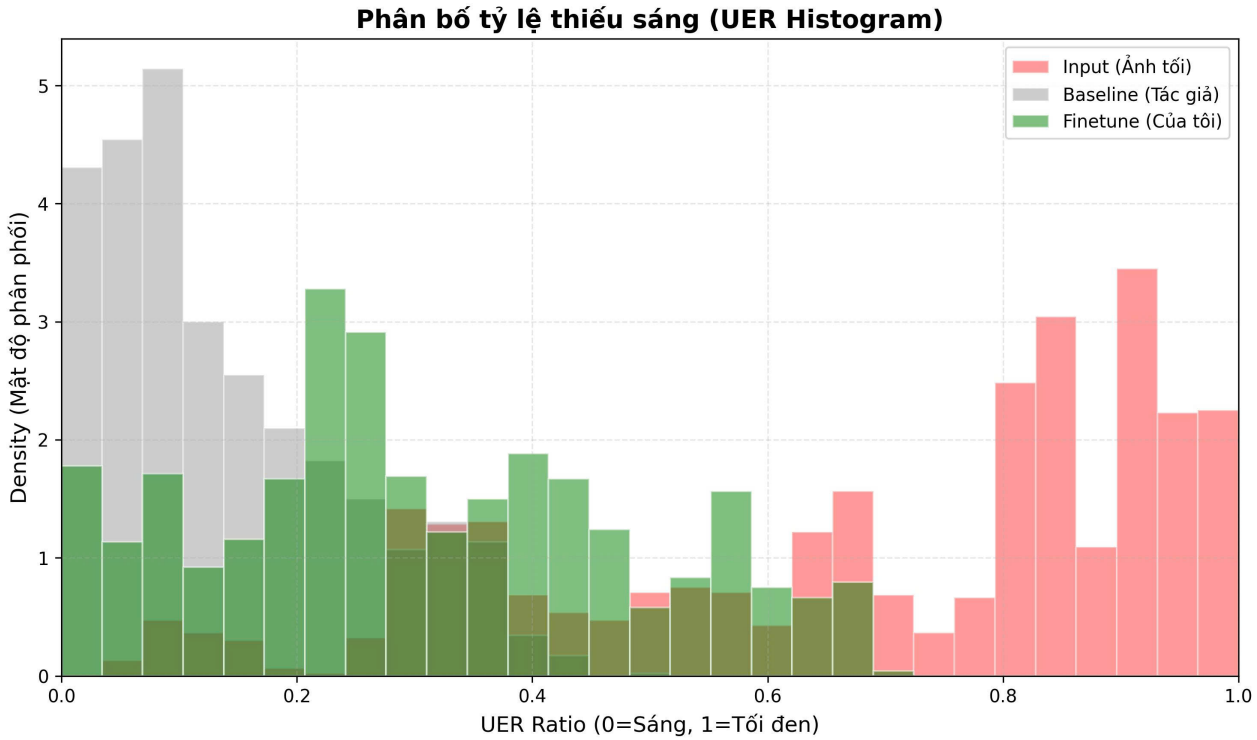
**Histogram VOL** Histogram VOL phản ánh mức độ sắc nét của ảnh. Kết quả cho thấy phân bố VOL của ảnh đầu ra từ mô hình cải tiến có xu hướng dịch sang phải so với mô hình LEDNet gốc. Điều này cho thấy độ sắc nét tổng thể của ảnh được cải thiện, các chi tiết biên được phục hồi rõ ràng hơn.




Hình 3: Minh họa kiến trúc LEDNet

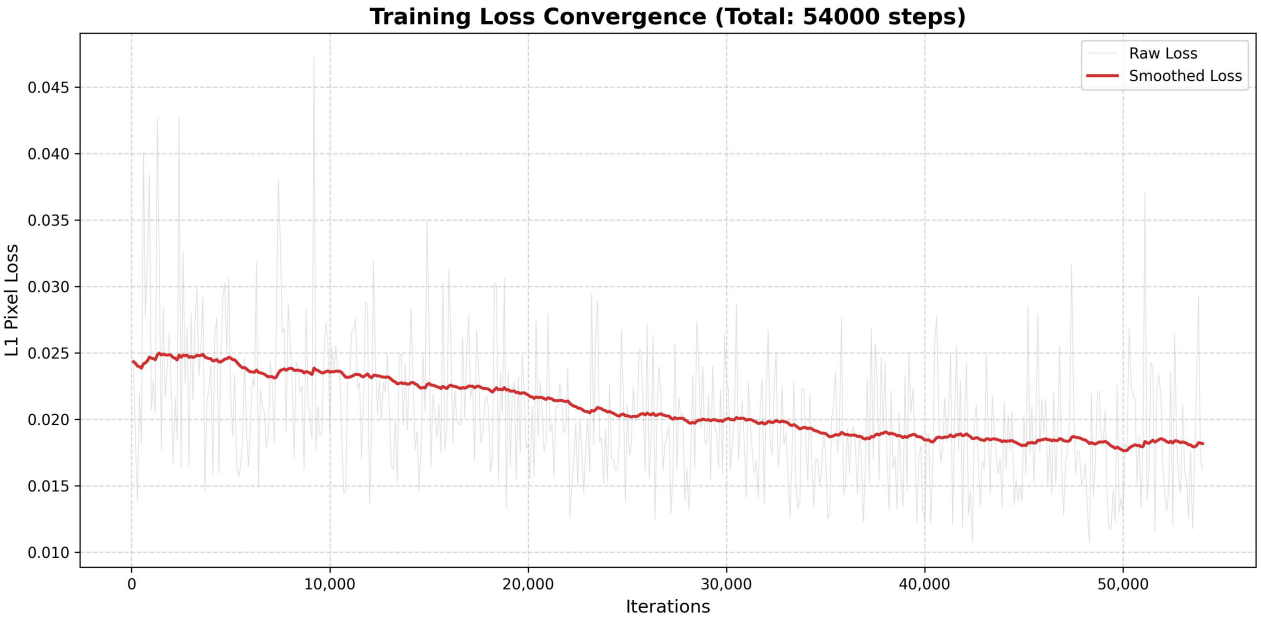
**Histogram UER** Histogram UER phản ánh mức độ thiếu sáng của ảnh. Phân bố UER của ảnh đầu ra từ mô hình cải tiến có xu hướng dịch sang trái, cho thấy tỉ lệ vùng ảnh bị thiếu sáng đã giảm đáng kể so với ảnh đầu vào và kết quả từ mô hình gốc.

Sự dịch chuyển đồng thời của histogram VOL và UER cho thấy mô hình cải tiến đạt được sự cân bằng tốt giữa tăng sáng và khử mờ.




Hình 4: Minh họa kiến trúc LEDNet

### 5.3 Phân tích quá trình hội tụ của hàm loss




Hình 5: Minh họa kiến trúc LEDNet

Hình minh họa quá trình hội tụ của hàm loss trong quá trình huấn luyện mô hình LEDNet kết hợp cơ chế trọng số động dựa trên chỉ số VOL và UER, với tổng số 54 000 bước huấn luyện. Trục hoành biểu diễn số vòng lặp (iterations), trong khi trục tung biểu diễn giá trị hàm mất mát L1 pixel loss. Biểu đồ bao gồm hai đường: loss thô (raw loss) và loss được làm mượt (smoothed loss).

- Nhận xét về xu hướng hội tụ: Quan sát đường loss làm mượt cho thấy giá trị loss giảm đều theo thời gian, từ khoảng 0.024–0.025 ở giai đoạn đầu xuống còn khoảng 0.018 ở giai đoạn cuối huấn luyện. Xu hướng giảm ổn định này cho thấy mô hình học hiệu quả và quá trình huấn luyện không gặp hiện tượng divergence hay mất ổn định. Sau khoảng 30 000 bước huấn luyện, loss bắt đầu tiến tới trạng thái bão hòa, phản ánh việc mô hình đã gần đạt trạng thái hội tụ.
- Dao động của loss thô và ảnh hưởng của trọng số VOL–UER: Đường loss thô có mức dao động tương đối lớn trong suốt quá trình huấn luyện. Hiện tượng này là phù hợp với bài toán và phương pháp đề xuất, do tập dữ liệu bao gồm các ảnh có mức độ mờ và thiếu sáng rất khác nhau. Việc áp dụng trọng số động dựa trên VOL và UER khiến các ảnh có độ khó cao đóng góp giá trị loss lớn hơn, dẫn đến các dao động cục bộ trong loss thô. Tuy nhiên, đường loss làm mượt vẫn duy trì xu hướng giảm rõ ràng, chứng tỏ cơ chế trọng số động không gây mất ổn định trong huấn luyện.
- Đánh giá tổng thể: Từ biểu đồ hội tụ có thể kết luận rằng phương pháp cải tiến giữ được tính ổn định của quá trình huấn luyện, đồng thời giúp mô hình tập trung học tốt hơn trên các ảnh có độ khó cao. Việc loss hội tụ mượt và không xuất hiện hiện tượng nổ loss cho thấy thiết kế trọng số VOL–UER là hợp lý và phù hợp để tích hợp vào quá trình finetune mô hình LEDNet.
- Phân tích kết quả: Từ các kết quả định lượng và định tính, có thể rút ra một số nhận xét chính như sau:
  - Việc kết hợp chỉ số VOL và UER giúp mô hình tập trung học tốt hơn đối với các ảnh có độ khó cao.
  - Mặc dù mức cải thiện PSNR và SSIM không lớn, chất lượng thị giác được cải thiện rõ rệt.
  - Histogram VOL và UER cung cấp một góc nhìn bổ sung, phản ánh tốt hơn sự cải thiện về độ sắc nét và ánh sáng so với các chỉ số truyền thống.
  - Phương pháp cải tiến không làm thay đổi kiến trúc mạng, do đó giữ được tính ổn định và khả năng tổng quát hóa của mô hình LEDNet gốc.

Những kết quả này chứng minh rằng việc tích hợp các chỉ số đánh giá chất lượng ảnh tường minh vào quá trình huấn luyện là một hướng tiếp cận hiệu quả cho bài toán tăng sáng và khử mờ ảnh thiếu sáng.

### 5.4 So sánh trực quan

Đánh giá trực quan được thực hiện bằng cách so sánh các ảnh đầu ra theo ba nhóm:

- Ảnh chuẩn (GT)
- Ảnh đầu ra từ mô hình LEDNet gốc
- Ảnh đầu ra từ mô hình LEDNet kết hợp VOL–UER



(a) Ảnh 1 (b) Ảnh 2 (c) Ảnh 3

(d) Ảnh 4 (e) Ảnh 5 (f) Ảnh 6

Hình 6: So sánh trực quan kết quả xử lý ảnh

Kết quả cho thấy mô hình cải tiến tạo ra ảnh có độ sáng đồng đều hơn, chi tiết biên rõ ràng hơn và ít nhiễu hơn, đặc biệt ở các vùng cực tối và vùng bị mờ nặng. So với LEDNet gốc, phương pháp cải tiến hạn chế hiện tượng over-sharpen và khuếch đại nhiễu.

## 6 Kết Luận

Báo cáo đã nghiên cứu mô hình LEDNet cho bài toán tăng sáng và khử mờ ảnh thiếu sáng, đồng thời đề xuất cải tiến bằng cách tích hợp các chỉ số VOL và UER vào quá trình huấn luyện. Cơ chế trọng số động giúp mô hình tập trung tốt hơn vào các ảnh có độ khó cao mà không cần thay đổi kiến trúc gốc. Kết quả thực nghiệm cho thấy chất lượng thị giác được cải thiện rõ rệt trong khi các chỉ số PSNR và SSIM vẫn được duy trì ổn định. Quá trình huấn luyện diễn ra ổn định, không xuất hiện hiện tượng mất kiểm soát. Phương pháp đề xuất chứng minh tính khả thi và hiệu quả trong việc nâng cao chất lượng ảnh thiếu sáng.

## 7 Lời Cảm Ơn

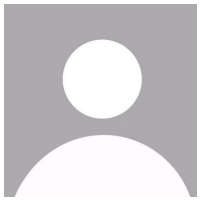
Em xin chân thành cảm ơn thầy Đào Việt đã tận tình chỉ dẫn, góp ý và hỗ trợ em trong suốt quá trình thực hiện báo cáo này. Em cũng xin cảm ơn các thầy cô trong khoa đã trang bị cho em những kiến thức nền tảng quý báu, giúp em hoàn thành tốt quá trình nghiên cứu. Bên cạnh đó, em xin cảm ơn bạn bè và những người đã hỗ trợ, động viên em trong quá trình học tập và thực hiện đề tài. Do thời gian và kiến thức còn hạn chế, báo cáo không tránh khỏi những thiếu sót, em rất mong nhận được sự góp ý của thầy cô để hoàn thiện hơn trong tương lai.

## Tài liệu

1. Liu, Y., Li, Y., Wang, X., Liu, Z., Chen, Y., Guo, B.: LEDNet: Joint Low-Light Enhancement and Deblurring. In: European Conference on Computer Vision (ECCV) (2022)



**Họ và tên:** Nguyễn Tiến Công
**Mã SV:** 0205268
**Nhiệm vụ chính:** Tìm hiểu và tổng hợp tài liệu liên quan đến bài toán và mô hình nghiên cứu. Phát triển và cải tiến mô hình. Lựa chọn và áp dụng các phương pháp đánh giá phù hợp cho bài toán. Tổng hợp kết quả và thực hiện viết báo cáo.



**Họ và tên:** Nguyễn Việt Tuấn Anh
**Mã SV:** 0204068
**Nhiệm vụ chính:** Thực hiện finetune mô hình LEDNet trên tập dữ liệu ảnh thiếu sáng và mờ. Đánh giá hiệu quả mô hình thông qua các chỉ số PSNR, SSIM và phân tích histogram VOL và UER. Thực hiện so sánh trực quan kết quả và tổng hợp, trình bày phần thực nghiệm trong báo cáo.



**Họ và tên:** Nguyễn Hồng Lịch
**Mã SV:** 0210068
**Nhiệm vụ chính:** Thực hiện chuẩn hóa dữ liệu đầu vào phục vụ huấn luyện mô hình, bao gồm tiền xử lý và chuẩn hóa giá trị ảnh. Đánh giá hiệu quả mô hình thông qua các chỉ số PSNR, SSIM, phân tích histogram VOL và UER, đồng thời thực hiện so sánh trực quan kết quả đầu ra.